

# Prédiction des pannes

Utilisation d'un réseau de neurones récurrents pour de la maintenance prédictive

---

Paul Vardon

Ecole Polytechnique - NASA

# Sommaire de la présentation

1. Introduction
2. Données
3. Algorithme
4. Résultats
5. Bilan

# Introduction

---

Le set d'entraînement est constitué de 20,631 entrées, réparties en 100 turbines qui tournent jusqu'à arrêt par panne.

Pour chaque turbine et chaque cycle, 3 paramètres de configurations opérationnelles et 20 paramètres de mesure sont disponibles.

Le set de test est constitué de 13,096 entrées, réparties elles aussi en 100 turbines. Les enregistrements s'arrêtent, pour chaque turbine, à un nombre arbitraire de cycles, correspondant ainsi à la réalité effective des observations.

Enfin, un set de mesures effectives des pannes des turbines du set d'entraînement est disponible.


# Objectif du travail

1. Prédire la RUL (Remaining Useful Life) de chaque turbine
2. Minimiser la MSE (Mean Squared Error) des prédictions
3. Proposer une solution au problème, ainsi qu'une mise en perspective de cette solution

# Données

---

# Répartition des pannes



**Figure 1** – Temps avant la première panne (train set)

# Répartition des paramètres

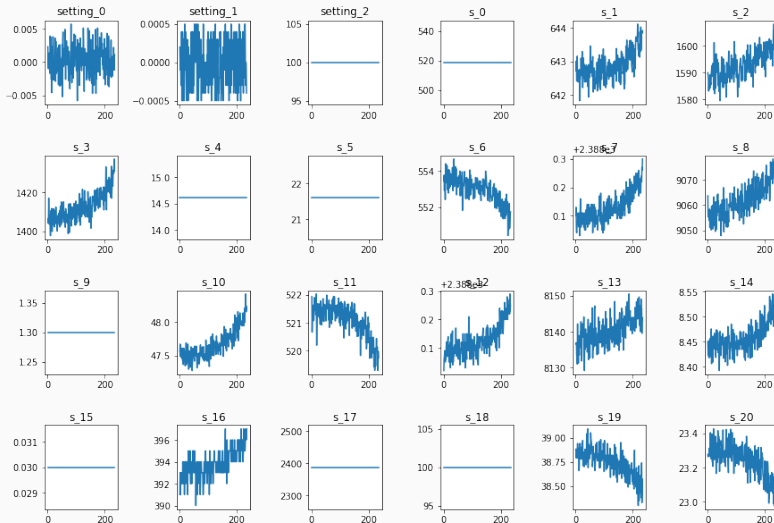



Figure 2 – Evolution des paramètres pour la 20e turbine



# Algorithme

---

# Réseau de neurones récurrents



**Figure 3** – Long Short Term Memory NN

Pour résoudre ce problème, on utilise un réseau LSTM, qui permet de propager dans le réseau une mémoire à long terme de l'évolution des données.

# Réseau de neurones récurrents


| Layer (type)              | Output Shape    | Param # |
|---------------------------|-----------------|---------|
| =====                     | =====           | =====   |
| lstm_0 (LSTM)             | (None, 50, 100) | 50400   |
| dropout_0 (Dropout)       | (None, 50, 100) | 0       |
| lstm_1 (LSTM)             | (None, 50, 50)  | 30200   |
| dropout_1 (Dropout)       | (None, 50, 50)  | 0       |
| lstm_2 (LSTM)             | (None, 25)      | 7600    |
| dropout_2 (Dropout)       | (None, 25)      | 0       |
| dense_0 (Dense)           | (None, 1)       | 26      |
| activation_0 (Activation) | (None, 1)       | 0       |
| =====                     | =====           | =====   |
| Total params: 88,226      |                 |         |
| Trainable params: 88,226  |                 |         |
| Non-trainable params: 0   |                 |         |
| None                      |                 |         |

Figure 4 – Implémentation du réseau de neurones


## Résultats

---

# Résultats d'entraînement



**Figure 5** – Mean Square Error sur le set d'entraînement



**Figure 6** – Comparaison Prediction/Réalité

# Bilan

---

| Estimateur             | Valeur |
|------------------------|--------|
| Mean Square Error      | 303.49 |
| Root Mean Square Error | 11.65  |
| Mean Absolute Error    | 11.65  |
| Efficiencie            | 85.79% |

**Figure 7** – Analyse statistique de l'occurrence des pannes

Les estimateurs RMSE et MAE sont comparatifs : ils donnent des informations sur l'efficacité du modèle en comparaison avec d'autres modèles. Les résultats permettent de conclure à la validité de la méthode adoptée.



## Problèmes potentiels

Les résultats ne permettent pas une systématisation de la prédiction. Ils constituent un **outil d'aide à la décision**.

## Améliorations

- Prise en compte de tous les cycles
- Optimisation des hyper-paramètres
- Instauration de seuils de maintenance

**Questions ?**

---